

WYZWANIE HACKATHONOWE

Transparent Data

<https://transparentdata.pl>

Ocena Sentymentu Firm na Podstawie Publikacji Medialnych

1. Kontekst i Motywacja

Instytucje finansowe i przedsiębiorstwa przeprowadzające procesy due diligence oraz weryfikację kontrahentów potrzebują narzędzi wspierających ocenę ryzyka nawiązania współpracy z daną firmą. Kluczowym elementem jest monitoring reputacji oparty na danych prasowych i medialnych — w szczególności wykrywanie powiązań firmy z działalnością korupcyjną, zarzutami wobec zarządu czy innymi zdarzeniami wysokiego ryzyka.

Wyzwanie wpisuje się w obszar wsparcia procesów AML (Anti-Money Laundering) i ma na celu zbudowanie prototypu inteligentnego systemu agregującego dane medialne, analizującego ich wydźwięk i przypisującego firmom scoring reputacyjny.

2. Opis Wyzwania

Uczestnicy mają za zadanie zbudować system, który:

- Zbiera i agreguje dane medialne z ogólnodostępnych źródeł (portale informacyjne, bazy prasowe, serwisy branżowe)
- Tworzy i zarządza bazą firm wraz z ich wariantami nazw (pełna nazwa, skróty, homonimy, numery rejestrowe jak NIP)
- Analizuje artykuły pod kątem sentymentu i powiązania z kluczowymi słowami ryzyka (np. "łapówka", "zarzuty", "zarząd", "sankcje")
- Generuje scoring reputacyjny dla firm i śledzi jego zmiany w czasie

Cel główny

Zbudowanie działającego prototypu systemu monitorowania reputacji firm, z naciskiem na algorytm analizy artykułów i obliczania ryzyka. System powinien działać w trybie online (dane bieżące) z możliwością analizy danych historycznych z danego zakresu dat.

3. Zakres Problemu

Obszar	Szczegóły
Typ sentymentu	Monitoring reputacji — wsparcie procesu AML
Słowa kluczowe ryzyka	łapówka, zarzuty, zarząd, korupcja, sankcje, pranie pieniędzy, oszustwo, wyłudzenie

Identyfikacja firm	Pełne nazwy, skróty, homonimy, NIP i inne numery rejestrowe
Źródła danych	Ogólnodostępne — portale informacyjne, media branżowe, bazy prasowe
Zakres geograficzny	Polska (priorytet), opcjonalnie UE
Zakres czasowy	Bieżący rok (rozszerzalny o zakres dat)
Tryb działania	Online (real-time) + dane historyczne

4. Kryteria Sukcesu

Kluczowym elementem oceny będzie jakość i innowacyjność algorytmu analizy treści i obliczania ryzyka, a nie samo zbieranie danych. Poniżej zestaw oczekiwanych elementów:

Wymagania podstawowe (must-have)

- Algorytm analizy sentymentu artykułów z uwzględnieniem kontekstu branży
- Mechanizm scoringu reputacyjnego dla firm (wartość + historia zmian w czasie)
- Rejestr firm z obsługą wielu wariantów nazw i identyfikatorów
- Działające demo systemu na przykładowych danych

Wymagania dodatkowe (nice-to-have)

- Aplikacja webowa lub mobilna prezentująca wyniki
- Wizualizacja trendów scoringu w czasie
- Pipeline danych zbierający artykuły automatycznie (crawler)
- Powiązanie scoringu z danymi giełdowymi i zmianami kursów akcji

5. Stos Technologiczny

Uczestnicy mają pełną swobodę wyboru technologii — zarówno rozwiązania lokalne, jak i dostęp do modeli przez API. Wybór powinien odzwierciedlać cel: działający prototyp z naciskiem na algorytm, nie infrastrukturę.

6. Metryki Oceny Projektu

Kryterium	Waga	Maks. punkty
Jakość algorytmu analizy sentymentu i ryzyka	Wysoka	30
Innowacyjność podejścia do scoringu firm	Wysoka	25
Działające demo / prototyp	Wysoka	20
Jakość prezentacji i dokumentacji	Średnia	10
UI/UX aplikacji (jeśli dotyczy)	Średnia	10
Elementy dodatkowe (giełda, sankcje, crawler)	Wysoka	30

7. Wskazówki dla Uczestników

Na co postawić nacisk?

- Skupcie się na algorytmie — to jest serce wyzwania. Dobry model analizy treści ważniejszy niż rozbudowana infrastruktura
- Zbieranie danych może być czasochłonne — możecie przygotować wcześniej zestaw przykładowych artykułów do demonstracji
- Obsługa wielu języków jest kluczowe — uwzględnijcie fleksję, synonimy i kontekst branżowy
- Nazwy firm mogą występować w wielu formach — zaplanujcie mechanizm ich ujednolicania (fuzzy matching, NIP itp.)
- Historia scoringu w czasie to ważna wartość — pokażcie jak ryzyko firmy ewoluuje